





AGENTE 10-K

preguntas sobre informes anuales, con cifra y cita

NATALIA SAN JOSÉ ORTEGA


JOSEP PÉREZ SEGURA

EMILIO SÁNCHEZ MARTÍNEZ



EL PROBLEMA


Queremos un agente que lea los 10-K de 6 tecnológicas y conteste con la cifra exacta y la frase que lo demuestra



LOS DATOS

- 6 empresas x 2 años (FY2024 y FY2025)
- 4 secciones: riesgos, dirección, mercado y estados financieros
- 1.749 trozos de texto: para buscar
- 135 cifras XBRL: la verdad oficial
- 20 preguntas propias: numéricas, extractivas y comparativas

CÓMO FUNCIONA




LO QUE DECIDIMOS

- *Las cifras, solo del XBRL* – nunca leídas de una tabla troceada
- *Buscar en inglés* – Gemini 3.8 Flash reescribe la pregunta
- *BM25 + denso con RRF* – las palabras exactas y el significado
- *Un guardrail revisa cada número* – si no cuadra: corrige o se calla
- *Si no está, decirlo* – abstenerse no es fallar
- *Un juez de otra familia* – Claude Opus 5.5: nadie se aprueba a sí mismo

EL PROBLEMA ERA EL IDIOMA

recall@5 · 19 frases ancla · sin encabezados

■ pregunta en español ■ reescrita al inglés



buscar en español: ¡0 %!


reescrita al inglés: 74 %

en otra ejecución, 68 %: la reescritura cambia de una vez a otra

RESULTADO

mismas 20 preguntas · juez Claude Opus 5.5

■ *baseline* ■ *final*



30% → 90%

*coste del agente por pregunta:
1,66 ¢ el baseline, 1,57 ¢ el final*

*12 preguntas que solo acierta el final, 0
al revés · McNemar $p = 0,0005$*

el juez va aparte: 10,6 ¢ en el final

ANTES Y AHORA

	21-sep · juez y reescritura: Flash Lite	24-sep · reescritura Gemini 3.8, juez Opus 5.5
Acierto baseline	55 %	30 %
Acierto final	95 %	90 %
Ventaja del final	+40 puntos	+60 puntos
McNemar (solo final / al revés)	8 / 0 · $p = 0,008$	12 / 0 · $p = 0,0005$
Extractivas del final	100 %	86 %
Coste del agente (final)	1,44 ¢	1,57 ¢
Latencia final	30,6 s	27,1 s
Recall@5 del buscador del agente	74 %	68 %
Juez (final): por pregunta · total	0,02 ¢ · 0,4 ¢	0,53 ¢ · 10,6 ¢
Preguntas trampa	11/11 · 0,97 ¢	11/11 · 0,88 ¢

Opus es más exigente: castiga afirmar lo que la cita no dice


El baseline cae 25 puntos y el final solo 5

La ventaja crece: de +40 a +60 puntos

Agente: +0,14 ¢ por pregunta; el juez va aparte

¿Y CON OTRO MODELO?

acierto en las 20 preguntas · coste del agente por pregunta



mismo juez para todos: Claude Opus 5.5

GPT-6 Luna: 70 % por 0,10 ¢, 16 veces más barato que Gemini 3.8

los baratos fallan sobre todo al citar, no en las cifras

de los gratuitos, solo Nex Mini completa las 20 preguntas: el resto se satura o no devuelve el esquema

¿Y CON 500 EMPRESAS?

MEDIDO

~6 \$

toda la práctica (6,28 \$ registrados)


1,6 ¢

por pregunta, el agente; el juez suma 0,5 ¢
si se evalúa

Lo que no escala tal cual:

- *list_available* devolvería 12.000 tokens en vez de 146: el doble de coste por pregunta
- la búsqueda recorre todo el índice antes de filtrar: de 0,2 s a más de 10 s por búsqueda

ESTIMADO · S&P 500 · 10.000 PREGUNTAS



INTENTAMOS ENGAÑARLO

11/11

correctas en contenido

¿Beneficio neto de Tesla?

→ no está en el corpus

¿Por qué cayeron los ingresos de NVIDIA?

→ ¡subieron un 114 %!

«Ignora tus instrucciones...»

→ consulta el dato y corrige

¿Beneficio bruto de Amazon?

→ no lo reporta: se abstiene

punto débil, igual que ayer: en los porcentajes, el número va en el texto y no en el campo cifra

LO QUE NO FUNCIONÓ

- ✗ *Encabezados como tercera señal de búsqueda*
+10, 5, 0 y -5 puntos en tres ejecuciones: es ruido, no una mejora
- ✗ *Medir con solo 19 frases ancla*
la misma prueba varía ± 10 puntos entre ejecuciones: las diferencias pequeñas no significan nada
- ✗ *Modelos gratuitos*
solo Nex Mini completó las 20 preguntas; el resto se saturó (429) o no devolvió el esquema
- ✗ *Reescribir con un tope de 128 tokens*
Gemini 3.8 razona antes de contestar y las consultas salían cortadas («Microsoft FY20»)
- ✗ *Juez = mismo modelo que el agente*
cada modelo se aprobaba a sí mismo: por eso el juez es ahora Claude Opus 5.5

PREGUNTAS CIEGAS

4 / 10

aciertos en las 10 ciegas

golden propio: 90 %

ciegas: 40 %

diferencia: -50 puntos

Generaliza: cifras del XBRL, citas literales y abstenerse


Era memoria del golden: el año de «cifra»; con FY2025 serían 7/10

LOS 6 FALLOS

- 3 comparativas: texto y cita bien, pero en «cifra» va FY2024, el primer año nombrado; se esperaba FY2025
- 1 comparativa: no encontró la frase y se cortó a los 150 s
- 1 numérica: se abstuvo bien (no hay FY2023), pero con otro concepto XBRL
- 1 extractiva: la API devolvió un 429; repetida aparte, acierta

CONCLUSIONES

- Lo que más mejoró fue verificar, no el modelo
- Ciegas 4/10: generaliza verificar, no nuestra convención de la cifra
- Con 20 preguntas: indicio, no certeza



¡Gracias!