

Agente investigador sobre informes 10-K

Informe técnico de la práctica «LLMs aplicados a finanzas»

Grupo 2 · Natalia San José Ortega · Josep Pérez Segura · Emilio Sánchez Martínez

Resumen. Se ha construido un agente que responde preguntas sobre los informes 10-K de seis tecnológicas (FY2024 y FY2025) y acompaña cada respuesta de la cifra oficial (XBRL) y de una cita literal del informe. Sobre un golden propio de 20 preguntas, y con un juez externo (Claude Opus 5.5), el sistema final acierta el 90 % frente al 30 % del sistema de partida (McNemar 12 a 0, $p = 0,0005$), con un coste de agente de 1,57 ¢ por pregunta. La mejora procede sobre todo de la verificación: cifras contrastadas con el XBRL, citas literales, un guardrail y la reescritura de la consulta al inglés. Fuera del golden propio el acierto baja: 50 % en el golden oficial de clase y 40 % (4/10) en las 10 preguntas ciegas. Los fallos se concentran en las comparativas (0/4 en las ciegas), tres de ellas por una convención del campo cifra cuya causa y arreglo se documentan.

Índice

Índice	1
1. Objetivo y criterio de corrección	2
2. Datos	2
3. Arquitectura del agente	2
4. Decisiones de diseño	3
5. Metodología de evaluación	3
6. Resultados	4
6.1 Baseline frente a sistema final	4
6.2 Mejora medida de la búsqueda	4
6.3 Cambio respecto a la evaluación del 21 de septiembre	5
6.4 Comparación de modelos	5
6.5 Preguntas trampa	6
6.6 Generalización: golden oficial de clase	6
6.7 Preguntas ciegas (holdout)	6
7. Lo que no funcionó	7
8. Costes y escalado	7
9. Limitaciones y mejoras	8
10. Reproducibilidad	8
11. Conclusiones	9

1. Objetivo y criterio de corrección

El objetivo es un agente que responda preguntas sobre informes anuales 10-K citando de dónde sale cada dato. El agente dispone de cuatro herramientas de coste y precisión muy distintos (una consulta exacta al XBRL, una búsqueda difusa sobre el texto y la lectura de una sección completa), y la tarea central es que decida bien entre ellas. Se evalúa con un conjunto de preguntas de respuesta conocida, midiendo calidad, coste y latencia.

El criterio de corrección es estricto: acertar por el camino equivocado cuenta como fallo. Una cifra leída de una tabla fragmentada puede coincidir por casualidad, pero ese procedimiento no generaliza; por ello las cifras deben proceder del XBRL y las afirmaciones cualitativas deben apoyarse en una frase literal del informe.

2. Datos

El corpus contiene los 10-K de NVIDIA, Microsoft, Apple, Alphabet, Meta y Amazon para FY2024 y FY2025, con cuatro secciones: Item 1A (riesgos), Item 7 (análisis de la dirección), Item 7A (riesgo de mercado) e Item 8 (estados financieros).

Elemento	Contenido	Herramienta
secciones.jsonl	48 secciones, unos 650.000 tokens	read_section
chunks.jsonl	1.749 fragmentos de ~500 tokens con su chunk_id	search_filings
xbrl_facts.parquet	135 hechos XBRL (13 conceptos), fuente autorizada de las cifras	get_xbrl_fact
indice/	Índice FAISS con bge-small-en-v1.5 (384 dimensiones)	search_filings

Tres particularidades condicionan el diseño: el ejercicio fiscal no coincide con el año natural (el FY2025 de NVIDIA cerró en enero de 2025); el concepto de ingresos no es universal (NVIDIA usa Revenues y el resto RevenueFromContractWithCustomer...); y hay huecos reales (Amazon no reporta GrossProfit), ante los que la respuesta correcta es abstenerse. El golden propio (src/golden_set_propio.jsonl) tiene 20 preguntas: 7 numéricas, 7 extractivas y 6 comparativas, con 19 frases ancla; supera el validador oficial de la sesión 1.

3. Arquitectura del agente




Figura 1. Arquitectura: el modelo decide en cada paso qué herramienta usar; un guardrail revisa las cifras antes de responder y un juez externo evalúa las citas.

El agente es un bucle LangChain con Gemini 3.8 Flash (temperatura 0, 4.096 tokens de salida) y salida estructurada obligatoria de ocho campos (respuesta, cifra, unidad, ticker, ejercicio, fuente, cita y chunk_id), ampliada con datos y citas para las comparativas. Sus componentes principales son:

- **Herramientas:** list_available, get_xbri_fact, search_filings y read_section, con los nombres y parámetros del contrato. search_filings reescribe la consulta al inglés, filtra por empresa, ejercicio e ítem y combina BM25 con búsqueda densa mediante RRF.
- **Guardrail** (verificar_cifras_contra_xbri): cada número de la respuesta debe ser un hecho XBRL consultado ($\pm 1\%$), una derivada permitida (variación del mismo concepto o margen del mismo ejercicio) o una cifra literal del texto recuperado. Si no, el modelo recibe el desajuste y dispone de un intento; después se abstiene. Las citas se reparan sin coste al tramo literal del fragmento.
- **Límites:** 8 llamadas a herramientas, 12 al modelo y 150 s por pregunta; reintentos ante rechazos temporales.
- **Interfaz:** responder(pregunta) y evaluar(ruta_jsonl) en agente/interfaz.py, generado desde el notebook entregable.

4. Decisiones de diseño

Decisión	Justificación
Cifras solo del XBRL	Es la cifra oficial, con decimales y unidad; evita leer tablas fragmentadas.
Reescritura al inglés	El modelo de embeddings es inglés; con la pregunta en español la búsqueda densa recupera un 0 %.
BM25 + denso con RRF	BM25 capta términos exactos y el denso el significado; RRF suma $1/(60 + \text{posición})$ porque las puntuaciones no son comparables.
Guardrail de cifras	Impide afirmar cifras no verificadas; sus falsos positivos (80 % iniciales: fechas y listas) se corrigieron.
Abstención explícita	Ante un dato inexistente, decirlo es la respuesta correcta.
Juez de otra familia	Un modelo tiende a aprobar sus propias respuestas; agente de Google, juez de Anthropic (Claude Opus 5.5).

5. Metodología de evaluación

Una pregunta es correcta solo si supera todos los evaluadores aplicables: **cita** (existe, es literal, procede de una herramienta, tiene metadatos coherentes y, según el juez LLM, respalda la respuesta; en comparativas, con evidencia de ambos ejercicios), **cifra** (coincide con el XBRL con tolerancia del 1 %; en comparativas, también ambos valores y las variaciones) y **trayectoria** (el agente pasó por la herramienta que tocaba). La coincidencia con la frase ancla del golden (cita_ancla) se reporta aparte porque mide recuperación, no validez.

La búsqueda se mide aparte con recall@k sobre las 19 frases ancla, en una matriz {denso, filtros, híbrido, híbrido con encabezados} $\times$ {consulta original, reescrita}, para poder atribuir cada mejora. La comparación entre versiones usa la prueba exacta de McNemar sobre las mismas preguntas. El juez es Claude Opus 5.5 y su coste se contabiliza aparte del agente. Con 20 preguntas, los porcentajes aislados tienen intervalos amplios (90 %: intervalo de Wilson 70–97 %).

6. Resultados

6.1 Baseline frente a sistema final

Evaluación completa del 24 de septiembre (resultados/s2/verificacion_20260924_opus), 20 de 20 preguntas evaluadas en ambas versiones. En negrita, el mejor valor.

Métrica	Baseline	Final
Acierto global	30,0 %	90,0 %
Acierto numéricas (7)	85,7 %	100,0 %
Acierto extractivas (7)	0,0 %	85,7 %
Acierto comparativas (6)	0,0 %	83,3 %
Cita válida	0,0 %	84,6 %
Cita sobre la frase ancla	46,2 %	92,3 %
Recall@5 del buscador (aislado)	26,3 %	68,4 %
Recall de la trayectoria	92,3 %	100,0 %
Coste medio del agente por pregunta	1,66 ¢	1,57 ¢
Latencia media	27,0 s	27,1 s
Llamadas a herramienta por pregunta	3,85	3,05
Coste del juez (evaluación, total)	6,7 ¢	10,6 ¢

Prueba de McNemar: 12 preguntas las acierta solo el sistema final y 0 solo el baseline ($p = 0,0005$). La mejora se concentra en extractivas y comparativas; el coste del agente no aumenta y la latencia es equivalente.

RESULTADO




Figura 2. Acierto por familia de pregunta, baseline frente a final (juez Claude Opus 5.5).

6.2 Mejora medida de la búsqueda

Variante	R@1	R@3	R@5	R@10
denso	0,0 %	0,0 %	0,0 %	0,0 %
filtros	5,3 %	10,5 %	26,3 %	47,4 %
híbrido	5,3 %	15,8 %	26,3 %	36,8 %
híbrido + encabezados	0,0 %	15,8 %	21,1 %	36,8 %

Variante	R@1	R@3	R@5	R@10
denso reescrito	15,8 %	21,1 %	26,3 %	47,4 %
filtros reescrito	26,3 %	57,9 %	63,2 %	84,2 %
híbrido reescrito	31,6 %	57,9 %	73,7 %	94,7 %
híbrido + encabezados reescrito (agente)	31,6 %	68,4 %	68,4 %	73,7 %

La reescritura al inglés es la mejora decisiva (0 % → 26-74 % en recall@5). Los filtros aportan unos 26 puntos; la fusión con BM25 y los encabezados tienen efectos que cambian de signo entre ejecuciones (ver sección 7). Medición: resultados/s2/retrieval/20260924T084746Z_7fb3e330.

6.3 Cambio respecto a la evaluación del 21 de septiembre

La evaluación del 21 de septiembre dio un 55 % y un 95 %, con Gemini 3.5 Flash Lite como reescritor y como juez. Con Claude Opus 5.5 como juez, más exigente, el baseline pierde cinco extractivas (propio-008, 009, 012, 013 y 014) por afirmar puntos que su cita no respalda. En el final cambian tres preguntas, todas por la cita: propio-015 pasa a acierto y propio-011 y propio-018 a fallo. La ventaja del sistema final crece de +40 a +60 puntos. El 95 % ya no corresponde al código actual; para reproducirlo deben fijarse MODELO_AUX_10K y MODELO_JUEZ_10K a Gemini 3.5 Flash Lite.

ANTES Y AHORA

	21-sep · juez y reescritura: Flash Lite	24-sep · reescritura Gemini 3.8, juez Opus 5.5
Acierto baseline	55 %	30 %
Acierto final	95 %	90 %
Ventaja del final	+40 puntos	+60 puntos
McNemar (solo final / al revés)	8 / 0 · p = 0,008	12 / 0 · p = 0,0005
Extractivas del final	100 %	86 %
Coste del agente (final)	1,44 ¢	1,57 ¢
Latencia final	30,6 s	27,1 s
Recall@5 del buscador del agente	74 %	68 %
Juez (final): por pregunta · total	0,02 ¢ · 0,4 ¢	0,53 ¢ · 10,6 ¢
Preguntas trampa	11/11 · 0,97 ¢	11/11 · 0,88 ¢

Opus es más exigente: castiga afirmar lo que la cita no dice

El baseline cae 25 puntos y el final solo 5

La ventaja crece: de +40 a +60 puntos

Agente: +0,14 ¢ por pregunta; el juez va aparte

Figura 3. Comparación entre la evaluación del 21 y la del 24 de septiembre.

6.4 Comparación de modelos

Cada modelo actúa como agente y como reescritor, con el mismo juez (Claude Opus 5.5) para todos (resultados/s2/panel_modelos/20260924_juez_opus).

Modelo	Acierto	Numéricas	Extractivas	Comparativas	Coste agente
Gemini 3.8 Flash (final)	90 %	7/7	6/7	5/6	1,57 ¢
GPT-6 Luna	70 %	5/7	4/7	5/6	0,10 ¢
Gemini 3.5 Flash Lite	60 %	7/7	4/7	1/6	0,45 ¢
Nex N2.5 Mini (gratuito)	60 %	6/7	1/7	5/6	0 ¢
GLM 5.3 Flash	40 %	7/7	1/7	0/6	0,16 ¢
DeepSeek V4.1 Flash	40 %	3/7	3/7	2/6	0,21 ¢

Los modelos económicos resuelven las numéricas, que dependen del XBRL, pero fallan al citar. GPT-6 Luna ofrece un 70 % a un coste dieciséis veces menor. De los modelos gratuitos probados, solo Nex Mini completó la evaluación; el resto se saturó (429) o no devolvió la respuesta estructurada. Con 20 preguntas, diferencias de 10 puntos no son significativas.

6.5 Preguntas trampa

Once preguntas fuera del golden (src/preguntas_trampa.jsonl), sin ajustes posteriores: concepto inexistente, concepto XBRL con otro nombre, ejercicio desplazado, empresa y ejercicio fuera del corpus, premisa falsa, unidad por acción, comparación entre empresas, sección fuera del corpus, cálculo entre ejercicios e instrucción inyectada. Resultado: 11 de 11 correctas en contenido (0,88 ¢ y 18,7 s de media). Debilidad: en la pregunta de porcentaje, el valor correcto figura en el texto pero el campo cifra contiene otro dato; el guardrail no lo detecta porque ese valor está respaldado.

6.6 Generalización: golden oficial de clase

Como aproximación a las preguntas ciegas, el agente final se evaluó sobre el golden oficial de clase (Clase_2/golden_set.jsonl, 20 preguntas no utilizadas para iterar), desde un clon limpio del repositorio (resultados/s2/golden_oficial/20260924T101726Z_d2a8d585).

Familia	Acierto	Observación
Numéricas	7/7 (100 %)	Incluye el concepto Revenues de NVIDIA y Alphabet.
Extractivas	3/6 (50 %)	Dos citas rechazadas por el juez y una pregunta cerrada por el límite de 150 s.
Comparativas	0/7 (0 %)	Seis fallan por el evaluador de cifra; la respuesta en prosa es correcta.
Total	10/20 (50 %)	Coste de agente 1,92 ¢ por pregunta; latencia media 58 s.

Causa de las comparativas. Las instrucciones del agente fijan que «la cifra principal corresponde al ejercicio preguntado primero». En el golden propio las comparativas preguntan primero por FY2025, pero las oficiales dicen «entre FY2024 y FY2025», de modo que el agente coloca en cifra el valor de FY2024 y el golden oficial espera el de FY2025. **Arreglo propuesto, no aplicado:** «en comparativas, la cifra principal es la del ejercicio más reciente». Es un cambio de una línea que no altera el golden propio; no se ha aplicado para no modificar el agente entregado sin volver a medirlo. Las preguntas ciegas lo confirman (sección 6.7).

6.7 Preguntas ciegas (holdout)

Las 10 preguntas ciegas (holdout.jsonl) se ejecutaron el 24 de septiembre sobre el repositorio entregado, sin modificar código y con la configuración final: agente Gemini 3.8 Flash y juez Claude Opus 5.5 (resultados/s2/holdout/20260924_holdout). Dos de ellas no tienen respuesta en el corpus y exigen abstenerse.

ID	Familia	Pregunta	Resultado	Causa
ho-001	Extractiva	Suministro de obleas (NVIDIA, FY2024)	Acierto	—
ho-002	Extractiva	Exposición a divisas (Alphabet, FY2025)	Acierto	—
ho-003	Extractiva	Ventas en la Gran China (Apple, FY2025)	Error	429 de Google a través de OpenRouter; repetida aparte, acierta
ho-004	Numérica	Activo total (Microsoft, FY2024)	Acierto	—
ho-005	Numérica	Beneficio bruto de Amazon (no etiquetado)	Acierto	Abstención correcta
ho-006	Numérica	Ingresos de NVIDIA en FY2023 (fuera del corpus)	Fallo	Abstención correcta, pero consultó RevenueFromContract... y la trayectoria exige Revenues

ID	Familia	Pregunta	Resultado	Causa
ho-007	Comparativa	Ingresos de Apple e iPhone	Fallo	Texto y cita correctos; cifra = FY2024
ho-008	Comparativa	I+D de Alphabet y compensación	Fallo	Cinco búsquedas sin la frase; límite de 150 s
ho-009	Comparativa	Beneficio y margen bruto de NVIDIA	Fallo	Texto y cita correctos; cifra = FY2024
ho-010	Comparativa	Beneficio operativo de Microsoft	Fallo	Texto y cita correctos; cifra = FY2024

Familia	Golden propio	Golden oficial	Ciegas
Numéricas	7/7 (100 %)	7/7 (100 %)	2/3 (67 %)
Extractivas	6/7 (86 %)	3/6 (50 %)	2/3 (67 %)
Comparativas	5/6 (83 %)	0/7 (0 %)	0/4 (0 %)
Total	18/20 (90 %)	10/20 (50 %)	4/10 (40 %)
Coste de agente por pregunta	1,57 ¢	1,92 ¢	1,74 ¢
Latencia media	27 s	58 s	50 s

Lectura. Frente al golden propio, las ciegas quedan 50 puntos por debajo. De los seis fallos, solo ho-008 es un fallo de contenido: no encontró la frase de la segunda parte y se cerró por tiempo. Tres son la convención del campo cifra de la sección 6.6: la respuesta y la cita son correctas y el juez las aprueba, pero el campo cifra lleva el ejercicio nombrado primero. Volviendo a puntuar esas mismas respuestas con el valor de FY2025 en cifra, sin llamar a la API, las tres pasan y el total sería 7/10. Los otros dos son un error 429 del proveedor (al repetir la pregunta, acierta: resultados/s2/holdout/20260924_reintento_ho003) y una abstención correcta que el evaluador de trayectoria penaliza porque exige el concepto XBRL exacto. **Parte general de la mejora:** cifras verificadas con el XBRL, citas literales y abstenerse cuando falta el dato. **Parte ajustada al golden propio:** la convención de la cifra en comparativas, que coincidía con la redacción de nuestras preguntas.

7. Lo que no funcionó

- **Encabezados como tercera señal del RRF:** +10,5, 0 y -5 puntos de recall@5 en tres mediciones; es ruido. Se mantiene activa por defecto, aunque la evidencia no la respalda.
- **Medir con 19 frases ancla:** la misma prueba varía en torno a ± 10 puntos entre ejecuciones porque la reescritura no es determinista.
- **Modelos gratuitos:** de una docena probada, solo Nex Mini completó las 20 preguntas.
- **Tope de 128 tokens en la reescritura:** Gemini 3.8 Flash razona antes de responder y las consultas salían truncadas («Microsoft FY20»); se amplió a 1.024.
- **Juez igual al agente:** cada modelo tendía a aprobarse (Nex Mini, 75 % juzgándose a sí mismo frente a 60-70 % con juez externo); se pasó a un juez de otra familia.
- **Troceado sin partir tablas** (scripts/experimento_chunking.py): +10 puntos en el híbrido sin encabezados, pero -5 con encabezados y sin significación con 19 anclas; no se adoptó.

8. Costes y escalado

Coste total registrado de la práctica: 6,28 \$ (5,06 \$ de agente, 0,83 \$ de juez y 0,39 \$ de pruebas). Por pregunta, el agente cuesta 1,57 ¢ (12.200 tokens de entrada, 2.100 de salida y 3,6 llamadas al modelo) y el juez 0,53 ¢.

¿Y CON 500 EMPRESAS?

MEDIDO

~6 \$

toda la práctica (6,28 \$ registrados)

1,6 ¢

por pregunta, el agente; el juez suma 0,5 ¢ si se evalúa

Lo que no escala tal cual:

- *list_available* devolvería 12.000 tokens en vez de 146: el doble de coste por pregunta
- la búsqueda recorre todo el índice antes de filtrar: de 0,2 s a más de 10 s por búsqueda

ESTIMADO · S&P 500 · 10.000 PREGUNTAS




Figura 4. Coste medido y estimación para el S&P 500 (scripts/estimar_escala.py).

Para el S&P 500 (1.000 informes, unos 146.000 fragmentos, índice de 224 MB y 2,4 h de embeddings en local) y 20 preguntas por empresa, se estiman unos 160 \$ con Gemini 3.8 Flash y unos 10 \$ con GPT-6 Luna; el juez costaría 53 \$ sobre todo o 2,7 \$ sobre una muestra del 5 %. El diseño no escala sin cambios: *list_available* devolvería unos 12.000 tokens (≈ 320 \$ en total) y la búsqueda, que filtra después de recorrer todo el índice, pasaría de 0,2 s a más de 10 s. Las soluciones son filtrar el catálogo por empresa e indexar por empresa.

9. Limitaciones y mejoras

- **Convención del campo cifra en comparativas** (secciones 6.6 y 6.7): falla ante preguntas redactadas como «entre FY2024 y FY2025»; confirmada en las ciegas, con un arreglo de una línea.
- **Preguntas de dos partes**: en ho-008 el agente encontró las cifras pero no la frase de la segunda parte y agotó el límite de 150 s; el `recall@5` de la búsqueda ronda el 70 %.
- **Sin reintentos ante un 429**: si el proveedor limita temporalmente las peticiones durante la reescritura de la consulta, la pregunta entera falla (ho-003). Un reintento con espera lo evitaría.
- **Evaluador de trayectoria**: exige el concepto XBRL exacto y penaliza una abstención correcta hecha con un concepto equivalente (ho-006).
- **Campo cifra en preguntas de porcentaje**: el guardrail verifica soporte, no que la cifra responda a la pregunta.
- **Tamaño de muestra**: 20 preguntas y una sola ejecución por configuración; las conclusiones se apoyan en McNemar.
- **Latencia**: 27 s por pregunta en el golden propio y 58 s en el oficial, por el limitador de 0,3 peticiones por segundo y el razonamiento del modelo.
- **Escalado**: *list_available* y el filtrado posterior de la búsqueda (sección 8).
- **Interfaz**: en `evaluar()`, el parámetro `etiqueta` selecciona también la versión del agente; un valor distinto de `baseline` o `final` hace fallar todas las preguntas. Se recomienda usar `evaluar(ruta)` sin etiqueta.

10. Reproducibilidad

El repositorio funciona sobre un clon limpio sin editar código (comprobado): el índice FAISS se extrae de los ZIP, la clave se lee del entorno o de `.env` y los 32 tests pasan. Cada evaluación guarda configuración, hashes, preguntas, respuestas con trazas, métricas y una copia del módulo. Comandos principales:

```
python -m unittest discover -s tests
python scripts/ejecutar_evaluacion_s2.py --salida resultados/s2/<carpeta>
python scripts/generar_resumen.py --comparacion <carpeta>/comparacion \
    --retrieval resultados/s2/retrieval/<marca>
python scripts/estimar_escalas.py
python -c "from agente.interfaz import evaluar; \
    print(evaluar('holdout.jsonl', salida='resultados/s2/holdout/<carpeta>'))"
```

Resultado	Ubicación
Evaluación principal (24-sep)	resultados/s2/verificacion_20260924_opus (con PROCEDENCIA.md)
Tabla resumen	resultados/RESUMEN.md
Búsqueda	resultados/s2/retrieval/20260924T084746Z_7fb3e330
Panel de modelos	resultados/s2/panel_modelos/20260924_juez_opus
Preguntas trampa	resultados/s2/trampas/20260924T084746Z_6dd5ef96
Golden oficial	resultados/s2/golden_oficial/20260924T101726Z_d2a8d585
Preguntas ciegas	resultados/s2/holdout/20260924_holdout
Repetición de ho-003	resultados/s2/holdout/20260924_reintento_ho003
Costes y escalado	resultados/s2/escala
Evaluación del 21-sep	resultados/s2/comparacion/20260921T230019Z_c0888bbc

11. Conclusiones

- La mejora del agente procede de la verificación (cifras del XBRL, citas literales y guardrail) y de cruzar el idioma en la búsqueda, no del cambio de modelo: del 30 % al 90 % con el mismo coste de agente.
- Con un juez más exigente la ventaja crece (de +40 a +60 puntos), lo que refuerza la validez de las mejoras.
- Fuera del golden propio el acierto baja: 50 % en el golden oficial y 40 % en las ciegas, 50 puntos menos. Lo que generaliza es la verificación: cifras del XBRL, citas literales y abstenerse cuando no hay dato.
- Las comparativas no generalizan (0/7 y 0/4), sobre todo por una convención del campo cifra ajustada a nuestras preguntas; al reevaluar las respuestas de las ciegas con el ejercicio más reciente, el total sería 7/10.
- Con 20 preguntas los resultados son un indicio sólido, no una certeza; lo que no funcionó también es un resultado.