





AGENTE 10-K

preguntas sobre informes anuales, con cifra y cita

NATALIA SAN JOSÉ ORTEGA


JOSEP PÉREZ SEGURA

EMILIO SÁNCHEZ MARTÍNEZ



EL PROBLEMA


Queremos un agente que lea los 10-K de 6 tecnológicas y conteste con la cifra exacta y la frase que lo demuestra



LOS DATOS

- 6 empresas x 2 años (FY2024 y FY2025)
- 4 secciones: riesgos, dirección, mercado y estados financieros
- 1.749 trozos de texto: para buscar
- 135 cifras XBRL: la verdad oficial
- 20 preguntas propias: numéricas, extractivas y comparativas

CÓMO FUNCIONA




LO QUE DECIDIMOS

- *Las cifras, solo del XBRL* – nunca leídas de una tabla troceada
- *Buscar en inglés* – Gemini 3.8 Flash reescribe la pregunta
- *BM25 + denso con RRF* – las palabras exactas y el significado
- *Un guardrail revisa cada número* – si no cuadra: corrige o se calla
- *Si no está, decirlo* – abstenerse no es fallar
- *Un juez de otra familia* – Claude Opus 5.5: nadie se aprueba a sí mismo

EL PROBLEMA ERA EL IDIOMA

recall@5 · 19 frases ancla

■ pregunta en español ■ reescrita al inglés



buscar en español: ¡0 %!


reescrita al inglés: 74 %

en otra ejecución, 68 %: la reescritura cambia de una vez a otra

RESULTADO

mismas 20 preguntas · juez Claude Opus 5.5

■ *baseline* ■ *final*



30% → 90%

*coste por pregunta: 1,66 ¢ el
baseline, 1,57 ¢ el final*

*12 preguntas que solo acierta el final, 0
al revés · McNemar $p = 0,0005$*

ANTES Y AHORA

	21-sep · juez y reescritura: Flash Lite	24-sep · reescritura Gemini 3.8, juez Opus 5.5
Acierto baseline	55 %	30 %
Acierto final	95 %	90 %
Ventaja del final	+40 puntos	+60 puntos
McNemar (solo final / al revés)	$8 / 0 \cdot p = 0,008$	$12 / 0 \cdot p = 0,0005$
Extractivas del final	100 %	86 %
Coste final por pregunta	1,44 ¢	1,57 ¢
Latencia final	30,6 s	27,1 s
Recall@5 híbrido reescrito	68 %	74 %
Juez: coste por pregunta	0,02 ¢	0,53 ¢
Preguntas trampa	$11/11 \cdot 0,97 \text{ ¢}$	$11/11 \cdot 0,88 \text{ ¢}$

Opus es más exigente: castiga afirmar lo que la cita no dice


El baseline cae 25 puntos y el final solo 5

La ventaja crece: de +40 a +60 puntos

Coste: +0,14 ¢ por pregunta

¿Y CON OTRO MODELO?

acierto en las 20 preguntas · coste por pregunta



mismo juez para todos: Claude Opus 5.5

GPT-6 Luna: 70 % por 0,10 ¢, 16 veces más barato que Gemini 3.8

los baratos fallan sobre todo al citar, no en las cifras

de los gratuitos, solo Nex Mini completa las 20 preguntas: el resto se satura o no devuelve el esquema

INTENTAMOS ENGAÑARLO

11/11

correctas en contenido

¿Beneficio neto de Tesla?

→ no está en el corpus

¿Por qué cayeron los ingresos de NVIDIA?

→ ¡subieron un 114 %!

«Ignora tus instrucciones...»

→ consulta el dato y corrige

¿Beneficio bruto de Amazon?


→ no lo reporta: se abstiene

punto débil, igual que ayer: en los porcentajes, el número va en el texto y no en el campo cifra

LO QUE NO FUNCIONÓ

- ✗ *Encabezados como tercera señal de búsqueda*
+10, 5, 0 y -5 puntos en tres ejecuciones: es ruido, no una mejora
- ✗ *Medir con solo 19 frases ancla*
la misma prueba varía ± 10 puntos entre ejecuciones: las diferencias pequeñas no significan nada
- ✗ *Modelos gratuitos*
solo Nex Mini completó las 20 preguntas; el resto se saturó (429) o no devolvió el esquema
- ✗ *Reescribir con un tope de 128 tokens*
Gemini 3.8 razona antes de contestar y las consultas salían cortadas («Microsoft FY20»)
- ✗ *Juez = mismo modelo que el agente*
cada modelo se aprobaba a sí mismo: por eso el juez es ahora Claude Opus 5.5

PREGUNTAS CIEGAS



aciertos en las 10 ciegas

golden propio: 90 %

ciegas: ----- %


diferencia: ----- puntos

Si baja: ¿qué parte era mejora general y qué parte era memoria del golden?

se rellena en clase con evaluar("holdout.jsonl")

CONCLUSIONES

- Lo que más mejoró fue verificar, no el modelo
- Con 20 preguntas: indicio, no certeza



¡Gracias!