

Agente sobre informes 10-K: robustez y evaluación

Estado: evaluación incompleta. Informe provisional; no permite concluir qué agente es mejor.

Modelo: openrouter:google/gemini-3.8-flash. Temperatura: 0; máximo de tokens de salida por llamada: 4096; k: 5.

Diseño y funcionamiento

Se comparan el baseline propio y el agente final con las mismas 20 preguntas: 7 numéricas, 7 extractivas y 6 comparativas. El corpus contiene 48 secciones de seis compañías en dos ejercicios; las comparativas aportan evidencia de ambos años.

El agente consulta `get_xbrl_fact` para cifras, `search_filings` para texto, `read_section` para una sección completa y `list_available` para comprobar cobertura. El sistema final incorpora filtros, fusión BM25/densa por posiciones, etiqueta de encabezado y reescritura al inglés. Conserva decimales XBRL, repara la cita al tramo literal del fragmento, comprueba cifras y permite una corrección antes de abstenerse; limita a 8 llamadas a herramientas y 12 al modelo por pregunta, con un corte de tiempo y las reescrituras registradas.

El acierto exige superar los criterios aplicables de cifra, cita y trayectoria. El criterio de cita es el del enunciado —que exista y respalde lo que se afirma—; que además caiga sobre la frase anclada en el golden se reporta aparte, porque eso mide recuperación y penalizaba pasajes distintos igualmente válidos. La cita se comprueba literalmente, con sus metadatos y procedencia, antes del juez semántico. Las preguntas numéricas sin anclas no necesitan juez. Los fallos técnicos se conservan y no se presentan como respuestas evaluadas.

Comparación de los agentes

Métrica	Baseline	Final
Preguntas evaluadas / 20	20.0000	19.0000
Acierto global	0.5500	0.9500
Acierto numéricas	0.8571	1.0000
Acierto extractivas	0.7143	0.8571
Acierto comparativas	0.0000	1.0000
Recall de la trayectoria	0.7692	0.8750
Coste medio agente (USD)	0.0145	0.0155
Preguntas con coste conocido	20.0000	20.0000
Latencia media (s)	24.2622	29.3904
Llamadas a herramientas	3.7500	3.1500

* Mejor valor observado (ambos si empatan), sólo con evaluación completa. Las tasas usan todas las preguntas, incluidos errores y pendientes. Las medias de coste y latencia excluyen valores desconocidos; con ejecución incompleta no describen una comparación válida. El coste del agente incluye reescritura; el juez se contabiliza por separado.

No se interpreta la diferencia de acierto entre agentes porque faltan evaluaciones. Los ceros de preguntas no intentadas no demuestran mala calidad del modelo.

Medición aislada de la búsqueda

Esta medición se conserva como experimento separado: modelo openrouter:google/gemini-3.8-flash, máximo de salida 4096 tokens. La comparación de agentes utiliza 4096 tokens. No se han repetido las consultas de este experimento al cambiar el límite de salida de los agentes.

Variante	Recall@1	Recall@3	Recall@5	Recall@10	Evidencias
denso	0.00%	0.00%	0.00%	0.00%	19
filtros	5.26%	10.53%	26.32%	47.37%	19
hibrido	5.26%	15.79%	26.32%	36.84%	19
hibrido_enc	0.00%	15.79%	21.05%	36.84%	19
denso_reescrito	15.79%	31.58%	36.84%	47.37%	19
filtros_reescrito	36.84%	63.16%	63.16%	84.21%	19
hibrido_reescrito	36.84%	57.89%	63.16%	100.00%	19
hibrido_enc_reescrito	31.58%	68.42%	73.68%	84.21%	19

La matriz separa las dos mejoras en lugar de encadenarlas, que es lo que permite atribuir las. Sobre la consulta original, los filtros cambian el recall@5 en +26.3 puntos y la fusión BM25 en +0.0. Reescribir la consulta cambia el filtrado en +36.8 puntos y el híbrido en +36.8: la reescritura es, sobre todo, traducción, porque las preguntas van en español y el corpus está en inglés. La etiqueta de encabezado añade +10.5 puntos sobre el híbrido reescrito. Los filtros proceden del golden: esta prueba aísla el buscador y no mide si el agente sabe elegirlos. El recall de la trayectoria agrega todas las búsquedas del agente y no equivale al recall@5.

Revisión de respuestas y costes

baseline: evaluado: 20.

Coste registrado del juez: 0.001361 USD en 5 preguntas con coste de juez informado.

Ejemplo propio-007: ¿Cuál fue el beneficio diluido por acción de Apple en FY2025, expresado en dólares por acción?

Respuesta: El beneficio diluido por acción (EarningsPerShareDiluted) de Apple en el ejercicio fiscal 2025 (FY2025) fue de 7,00 USD por acción.

Criterios: cifra=False; cita=None; trayectoria=True; acierto=False

Ejemplo propio-010: ¿Por qué una interrupción en el suministro de componentes críticos puede ser especialmente perjudicial para Apple, según su informe de FY2025?

Respuesta (extracto): Según el informe 10-K de Apple para el ejercicio fiscal 2025 (Item 1A), una interrupción en el suministro de componentes críticos puede ser especialmente perjudicial por las siguientes razones: 1. **Dependencia de fuentes únicas o limitadas (*single-source*)**: Apple obtiene ciertos componentes de fuentes únicas o limitadas, y sus nuevos productos frecuentemente requieren componentes personalizados que están disponibles a través de un solo proveedor. 2. **Dificultad de reemplazo y costes de transición**: Identificar y cualificar fuentes alternativas o realizar cambios en la cadena de suministro requiere un tiempo y recursos considerables, además de acarrear importantes riesgos regulatorios ...

Criterios: cifra=None; cita=False; trayectoria=True; acierto=False

La cita no superó las comprobaciones previas de literalidad, metadatos o evidencia recuperada; no se solicitó juicio semántico.

final: evaluado: 19; error: 1.

Coste registrado del juez: 0.003561 USD en 12 preguntas con coste de juez informado.

Ejemplo propio-001: ¿Cuál fue el total de activos de Apple al cierre de FY2024?

Respuesta: El total de activos de Apple al cierre de FY2024 fue de 364980000000 USD.

Criterios: cifra=True; cita=None; trayectoria=True; acierto=True

Incidencia registrada: RuntimeError: El agente terminó sin respuesta estructurada; puede haber alcanzado un límite

Reproducibilidad y límites

Ejecutar scripts/ejecutar_evaluacion_s2.py con --salida y una carpeta nueva. La clave se introduce de forma privada o mediante OPENROUTER_API_KEY. El notebook permite también ejecutar los bloques en orden. scripts/generar_informe_s2.py regenera este informe a partir de los CSV y las trazas. Las carpetas incluyen configuración, preguntas y hashes.

La validación del golden es local contra el corpus, no el validador externo del aula. Las 10 preguntas ciegas no están disponibles y su resultado y diferencia frente al golden quedan pendientes. Una muestra de 20 preguntas y un juez automático no garantizan generalización; se conservan respuestas y trazas para revisión humana.

La latencia depende de la red, la carga del proveedor y la caché local. Las versiones se ejecutan secuencialmente, primero baseline y después final; no es un ensayo aleatorizado de rendimiento. Los extractos del informe no sustituyen las respuestas completas guardadas en respuestas.jsonl.

Fuentes locales: resultados\s2\comparacion\20260921T222953Z_e54cd3c9 ;
resultados\s2\retrieval\20260921T215557Z_b69136ba