

Agente sobre informes 10-K: robustez y evaluación

Estado: evaluación incompleta. Informe provisional; no permite concluir qué agente es mejor.

Modelo: openrouter:google/gemini-3.8-flash. Temperatura: 0; máximo de tokens de salida por llamada: 1024; k: 5.

Diseño y funcionamiento

Se comparan el baseline propio y el agente final con las mismas 20 preguntas: 7 numéricas, 7 extractivas y 6 comparativas. El corpus contiene 48 secciones de seis compañías en dos ejercicios; las comparativas aportan evidencia de ambos años.

El agente consulta `get_xbrl_fact` para cifras, `search_filings` para texto, `read_section` para una sección completa y `list_available` para comprobar cobertura. El sistema final incorpora filtros, fusión BM25/densa por posiciones y reescritura al inglés. Conserva decimales XBRL, comprueba cifras y permite una corrección antes de abstenerse; limita a ocho llamadas a herramientas y diez al modelo, con reescrituras adicionales registradas.

El acierto exige superar los criterios aplicables de cifra, cita y trayectoria. La cita se comprueba literalmente, con sus metadatos y procedencia, antes del juez semántico. Las preguntas numéricas sin anclas no necesitan juez. Los fallos técnicos se conservan y no se presentan como respuestas evaluadas.

Comparación de los agentes

Métrica	Baseline	Final
Preguntas evaluadas / 20	4.0000	0.0000
Acierto global	0.2000	0.0000
Acierto numéricas	0.5714	0.0000
Acierto extractivas	0.0000	0.0000
Acierto comparativas	0.0000	0.0000
Recall de la trayectoria	No disponible	No disponible
Coste medio agente (USD)	0.0038	No disponible
Preguntas con coste conocido	4.0000	0.0000
Latencia media (s)	11.5746	4.5005
Llamadas a herramientas	1.4000	1.0000

* Mejor valor observado (ambos si empatan), sólo con evaluación completa. Las tasas usan todas las preguntas, incluidos errores y pendientes. Las medias de coste y latencia excluyen valores desconocidos; con ejecución incompleta no describen una comparación válida. El coste del agente incluye reescritura; el juez se contabiliza por separado.

No se interpreta la diferencia de acierto entre agentes porque faltan evaluaciones. Los ceros de preguntas no intentadas no demuestran mala calidad del modelo.

Medición aislada de la búsqueda

Variante	Recall@5	Evidencias
denso	0.00%	19
filtros	26.32%	19
hibrido	26.32%	19
hibrido_reescrito	73.68%	19

Los filtros cambian el recall en +26.3 puntos; la fusión híbrida añade +0.0; la reescritura añade +47.4. En esta medición, la fusión no mejoró el resultado del filtrado. Los filtros proceden del golden: esta prueba aísla el buscador y no mide si el agente sabe elegirlos. El recall de la trayectoria agrega todas las búsquedas del agente y no equivale al recall@5.

Revisión de respuestas y costes

baseline: no_intentado: 15; evaluado: 4; error: 1.

Coste registrado del juez: 0.000000 USD en 0 preguntas con coste de juez informado.

Ejemplo propio-001: ¿Cuál fue el total de activos de Apple al cierre de FY2024?

Respuesta: El total de activos de Apple al cierre del ejercicio fiscal 2024 (a fecha 28 de septiembre de 2024) fue de 364.980.000.000 USD (364.980 millones de dólares).

Criterios: cifra=True; cita=None; trayectoria=True; acierto=True

Incidencia registrada: PaymentRequiredResponseError: This request would exceed your available credits given your current in-flight requests. Retry after in-flight requests settle, or add credits.

final: no_intentado: 19; error: 1.

Coste registrado del juez: 0.000000 USD en 0 preguntas con coste de juez informado.

Incidencia registrada: PaymentRequiredResponseError: This request would exceed your available credits given your current in-flight requests. Retry after in-flight requests settle, or add credits.

Reproducibilidad y límites

Ejecutar scripts/ejecutar_evaluacion_s2.py con --salida y una carpeta nueva. La clave se introduce de forma privada o mediante OPENROUTER_API_KEY. El notebook permite también ejecutar los bloques en orden. scripts/generar_informe_s2.py regenera este informe a partir de los CSV y las trazas. Las carpetas incluyen configuración, preguntas y hashes.

La validación del golden es local contra el corpus, no el validador externo del aula. Las 10 preguntas ciegas no están disponibles y su resultado y diferencia frente al golden quedan pendientes. Una muestra de 20 preguntas y un juez automático no garantizan generalización; se conservan respuestas y trazas para revisión humana.

Fuentes locales: resultados\s2\verificacion_20260921\comparacion ;
resultados\s2\retrieval\20260921T114707Z_78cf7608